Прогнозирование продаж Favorita

Сравнение базовых, классических и нейросетевых моделей

Домашняя работа 3: Прогнозирование временных рядов

2026

1. Постановка задачи / Гипотезы

Цель проекта - прогнозирование ежедневных продаж товаров в магазинах Corporacion Favorita, крупной сети продуктовых магазинов в Эквадоре. Данные взяты из соревнования Kaggle "Corporacion Favorita Grocery Sales Forecasting".

Горизонт прогнозирования - 16 дней (1-16 августа 2017). Задача - предсказать unit_sales для множества комбинаций магазин-товар с использованием различных подходов: от простых бейзлайнов до градиентного бустинга и нейронных сетей.

Гипотезы

- Модели, использующие экзогенные признаки (акции, цена нефти, праздники), превзойдут чисто одномерные бейзлайны.
- Нейросетевые архитектуры (N-HiTS, TFT), способные обучаться на кросс-серийных паттернах, должны показать результаты на уровне или лучше градиентного бустинга.
- Temporal Fusion Transformer (TFT), разработанный для многошагового прогнозирования со смешанными входами, должен достичь лучшего качества.

2. Описание данных

Датасет Favorita содержит ежедневные записи о продажах тысяч товаров в 54 магазинах Эквадора с 2013 по 2017 год. Используются следующие файлы:

- train.csv: ~125 млн строк со столбцами: id, date, store_nbr, item_nbr, unit_sales, onpromotion.
- stores.csv: метаданные магазинов (город, штат, тип, кластер).
- items.csv: метаданные товаров (семейство, класс, флаг скоропортящегося товара).
- oil.csv: ежедневная цена нефти (dcoilwtico) - экономика Эквадора зависит от экспорта нефти.
- holidays_events.csv: национальные, региональные и местные праздники.
- transactions.csv: ежедневное количество транзакций по магазинам.

Предобработка

- Отрицательные unit_sales обрезаны до 0.
- onpromotion преобразован в бинарный (0/1), пропуски заполнены 0.
- Цена нефти: линейная интерполяция + прямое/обратное заполнение для пропущенных дат.
- Праздники: оставлены только непереносные национальные праздники как бинарный признак.
- 150 серий магазин-товар отобраны стратифицированной выборкой по типу магазина и семейству товара, с требованием >= 365 дней истории.

Разбиение Train / Validation / Test

- Train: до 2017-07-15.
- Validation: 2017-07-16 - 2017-07-31 (для ранней остановки LightGBM).
- Test: 2017-08-01 - 2017-08-16 (16-дневный горизонт, все метрики приводятся здесь).

3. Методология эксперимента

Эксперимент следует единому протоколу оценки для всех моделей:

- Все 150 серий используют одинаковое временное разбиение для обеспечения сопоставимости.
- Прогнозы обрезаны до >= 0 (продажи не могут быть отрицательными).
- На тестовом наборе вычисляются четыре метрики: RMSE, MAE, MAPE и NWRMSLE (взвешенный RMSLE с весом 1.25 для скоропортящихся товаров, как в соревновании Kaggle).
- Бейзлайновые и нейросетевые модели используют библиотеки StatsForecast / NeuralForecast в стандартном формате unique_id / ds / y.
- LightGBM использует пайплайн конструирования признаков с лаговыми, скользящими, временными и экзогенными признаками, обучение с ранней остановкой на валидации.

Конструирование признаков (LightGBM)

Для модели градиентного бустинга сконструированы следующие признаки:

- Временные: day_of_week, day_of_month, month, year, is_weekend, is_payday (15-е и последний день).
- Лаговые: unit_sales со сдвигом на 1, 7, 14, 28 дней.
- Скользящие статистики: среднее и стд. откл. за окна 7, 14, 28 дней (сдвиг на 1 для избежания утечки).
- Экзогенные: onpromotion, dcoilwtico (цена нефти), is_holiday.
- Категориальные: store_nbr, item_nbr, cluster (обрабатываются нативно LightGBM).

4. Описание моделей

4.1 Naive

Повторяет последнее наблюденное значение для всех 16 шагов прогноза. Служит простейшим бейзлайном.

4.2 Seasonal Naive

Повторяет значения того же дня недели из последней недели (season_length=7). Учитывает недельную сезонность без какого-либо обучения модели.

4.3 AutoTheta

Автоматический выбор лучшего варианта модели Theta. Theta декомпозирует ряд на долгосрочный тренд и краткосрочные компоненты, комбинируя их с экспоненциальным сглаживанием. Автовыбор оптимизирует коэффициент theta и применяет Standard Theta Method (STM) или Optimized Theta Method (OTM).

4.4 AutoETS

Автоматическое экспоненциальное сглаживание с выбором модели по компонентам Error, Trend и Seasonality. Рассматривает аддитивные/мультипликативные варианты и выбирает лучшую модель по информационным критериям (AIC/BIC).

4.5 LightGBM

Градиентный бустинг на деревьях решений с библиотекой LightGBM. Обучен как прямая многошаговая регрессия (одна модель, точечный прогноз на каждый шаг). Основные гиперпараметры: 500 раундов бустинга, 63 листа, learning rate 0.05, subsample 0.8, colsample 0.8, ранняя остановка после 50 раундов без улучшения на валидации. Использует GPU-ускорение.

4.6 N-HiTS (Neural Hierarchical Interpolation for Time Series)

Архитектура глубокого обучения, использующая многоскоростную дискретизацию сигнала и иерархическую интерполяцию для генерации прогнозов на разных временных масштабах. Размер входа = 48 (3x горизонт), обучение 5000 шагов с MAE loss, стандартное масштабирование, learning rate 1e-3, batch size 32.

4.7 TFT (Temporal Fusion Transformer)

Архитектура на основе трансформера для многошагового прогнозирования. Включает сети отбора переменных, gated residual networks и интерпретируемое многоголовое внимание. Конфигурация обучения как у N-HiTS: размер входа 48, 5000 шагов, MAE loss, стандартное масштабирование.

5. Результаты

5.1 Сводка метрик

В таблице ниже приведены результаты всех моделей на 16-дневном тестовом наборе. Лучшие значения по каждой метрике выделены зеленым/жирным.

Модель	RMSE	MAE	MAPE (%)	RMSLE
Naive	7.0282	2.9745	70.3758	0.6149
SeasonalNaive	6.7737	3.0537	80.8844	0.6480
AutoTheta	6.4624	2.7506	76.4068	0.5330
AutoETS	**6.4598**	2.7782	80.2085	0.5379
LightGBM	7.4508	2.9910	87.7094	0.5857
NHITS	7.6773	3.1806	78.0256	0.6287
TFT	6.5396	**2.5800**	**58.4757**	**0.5200**

Лучший RMSE: AutoETS (6.4598). Лучший MAE: TFT (2.5800). Лучший MAPE: TFT (58.48%). Лучший RMSLE: TFT (0.5200).

TFT достигает лучших результатов по всем четырем метрикам, подтверждая гипотезу о том, что архитектура трансформера с механизмом внимания и отбором переменных хорошо подходит для данной задачи многосерийного прогнозирования.

5.2 Диаграмма сравнения метрик

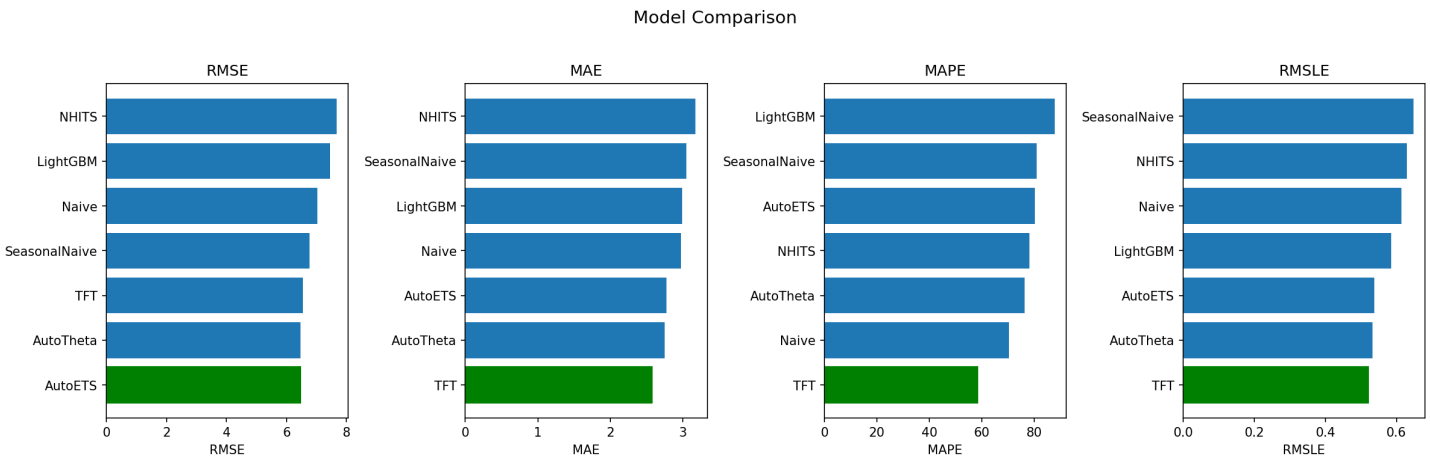

5.3 Примеры прогнозов

Ниже представлены графики прогнозов для случайно выбранных серий, показывающие фактические и прогнозные значения для всех моделей.

Серия: 17_583975

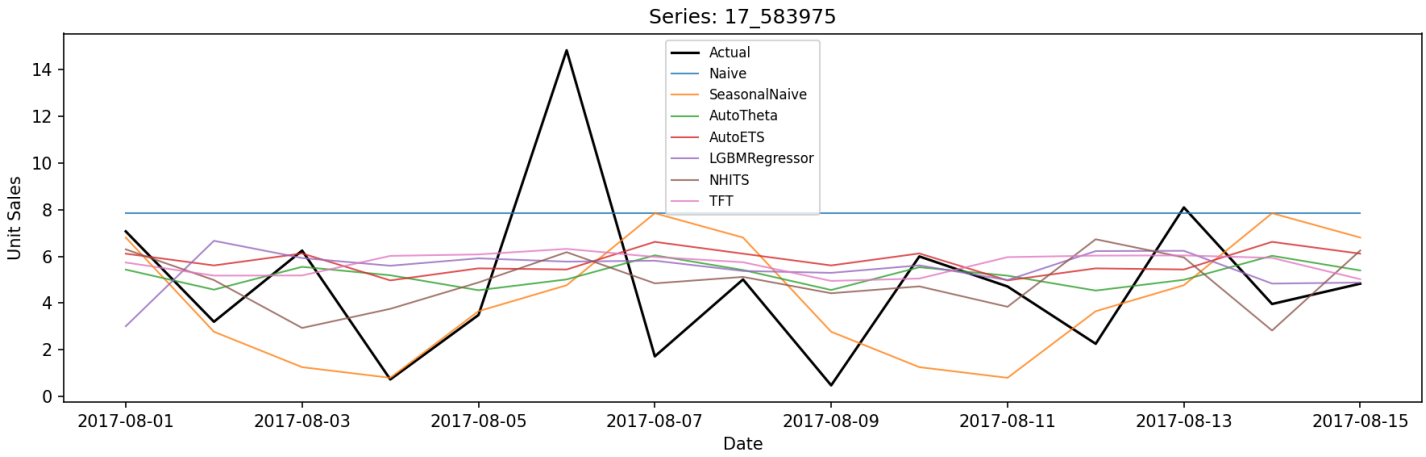

Серия: 28_1005456

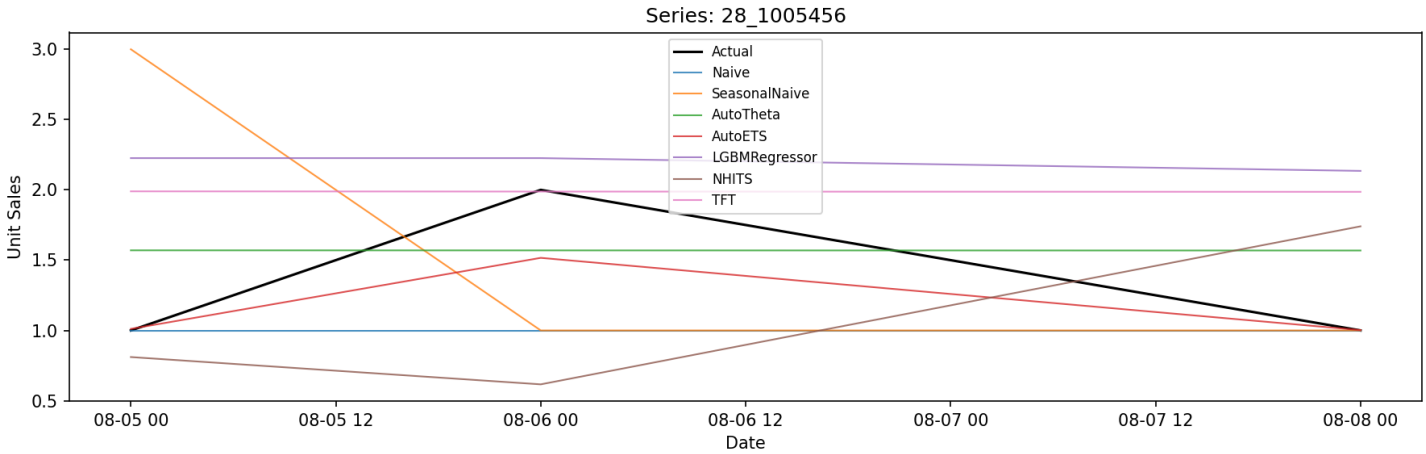

Серия: 28_557257

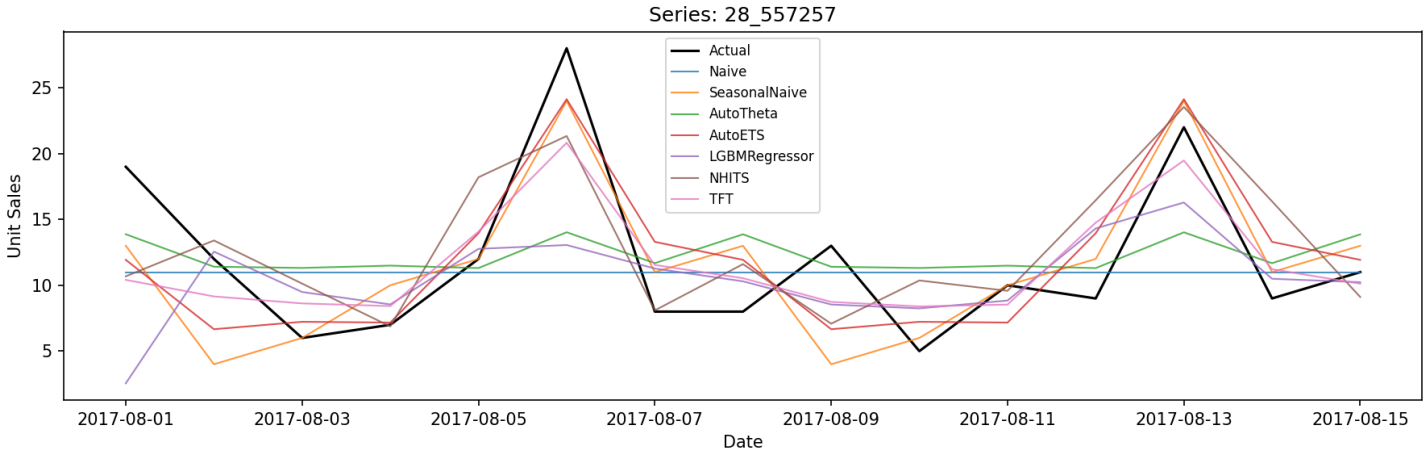

Серия: 31_812751

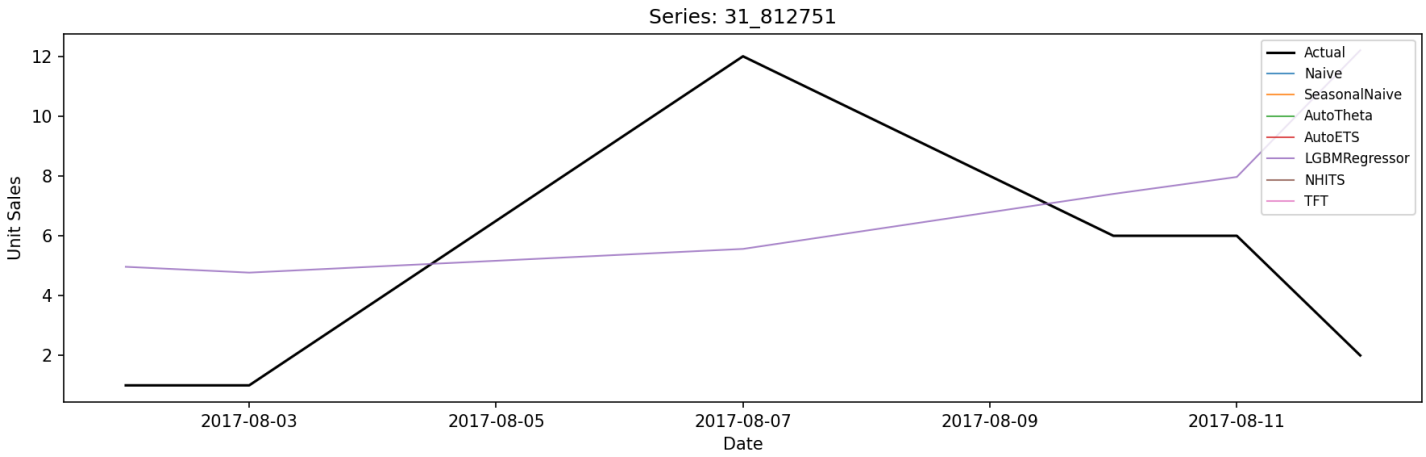

Серия: 39_463598

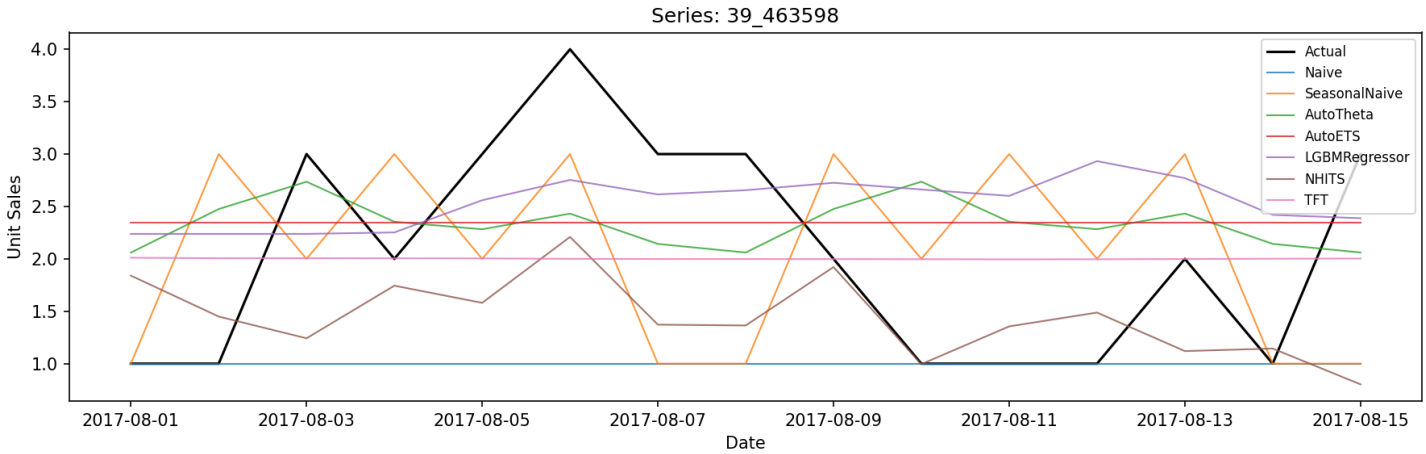

Серия: 45_1229642

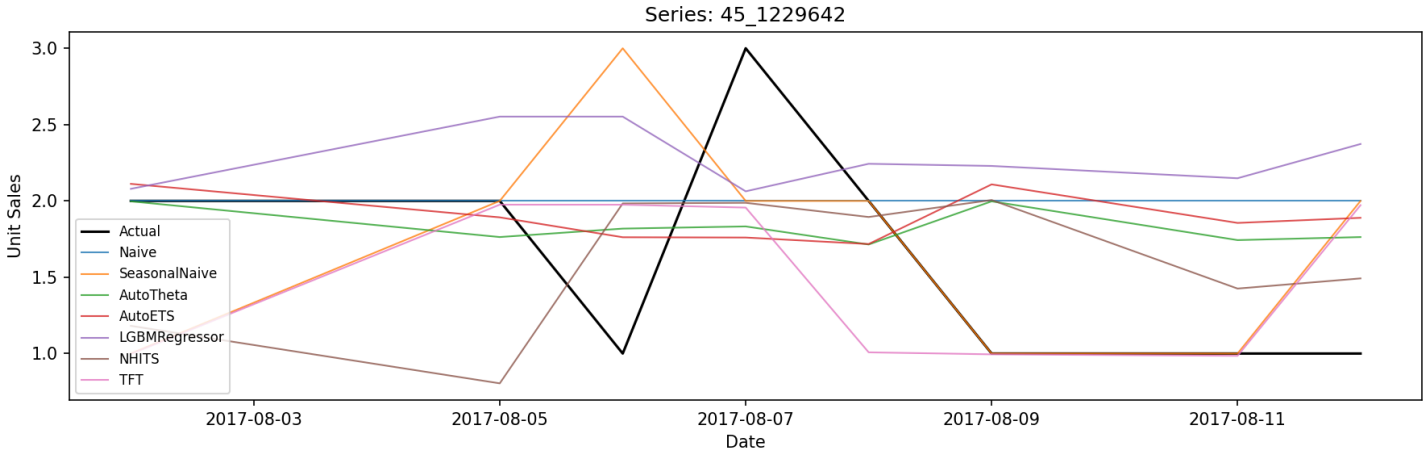

6. Выводы

1. TFT - лучшая модель в целом. Достигает наименьших RMSE (6.54), MAE (2.58), MAPE (58.48%) и RMSLE (0.52). Механизм внимания и отбор переменных позволяют эффективно использовать временные паттерны.

2. AutoTheta и AutoETS (классические статистические модели) показывают неожиданно хорошие результаты с RMSE около 6.46 - близко к TFT. Это свидетельствует о том, что хорошо настроенные методы экспоненциального сглаживания остаются конкурентоспособными бейзлайнами для ежедневного прогнозирования розничных продаж.

3. LightGBM показывает результаты ниже ожиданий (RMSE 7.45). Несмотря на доступ к богатым экзогенным признакам, подход прямого многошагового прогнозирования может страдать от накопления ошибок в лаговых признаках на тестовом наборе. Рекурсивная или multi-output стратегия могла бы улучшить результаты.

4. N-HiTS показывает наибольший RMSE (7.68) среди всех моделей. Гиперпараметры по умолчанию могут быть неоптимальны; дополнительная настройка архитектуры стеков и размеров ядер пулинга может улучшить качество.

5. Проверка гипотез: гипотеза о том, что экзогенные признаки улучшают прогнозирование, подтверждена частично - TFT выигрывает от способности интегрировать такую информацию, но LightGBM (который также использует экзогенные признаки) не превосходит более простые одномерные методы. Это говорит о том, что способность архитектуры обрабатывать признаки важна не менее самих признаков.

6. Метрика MAPE выявляет высокую вариативность: значения от 58% до 88%, что типично для прерывистых / низкообъемных серий продаж продуктов, где даже небольшие абсолютные ошибки приводят к большим процентным ошибкам.

7. Для промышленного внедрения рекомендуется TFT при наличии вычислительных ресурсов. В противном случае AutoETS/AutoTheta обеспечивают сильный бейзлайн с минимальными требованиями к инфраструктуре.